ADL : recapture

BAJI Jules

7 janvier 2024

1 Introduction

Avec les progrès de la technologie d'affichage des images et l'utilisation généralisée de divers dispositifs d'acquisition d'images, il devient très pratique et facile de recapturer des images de haute qualité à partir d'écrans LCD (affichage à cristaux liquides) de haute fidélité. Ces images recapturées constituent une menace sérieuse pour les technologies actuelles de criminalistique d'images et les systèmes de reconnaissance intelligents. Les applications critiques telles que l'identification biométrique des personnes (par exemple, la reconnaissance faciale) sont confrontées à des problèmes d'usurpation de visage, le système pouvant être trompé en montrant la photo d'une autre personne sur un écran électronique. Ce rapport vise à fournir un aperçu de deux solutions de reconnaissance de recapture, une par apprentissage de classificateur SVM et l'autre par analyse de descripteurs LTC. Le cadre applicatif ne se restreignant pas seulement à la forensique, ces propositions seront implémentées dans un jeu mobile, invitant les joueurs à capturer des images et à défier leurs contacts à les recréer avec précision.

2 Détection par apprentissage de classificateur SVM

Lors de la recapture, une perte de netteté est généralement subie, entraînant un lissage de l'image, et des distorsions visuelles dans des détails fins. La première solution [1] consiste en une comparaison des pixels des images originale et recapturée afin d'y retrouver ces différences générées par la recapture.

Pour chacune des 2 images originale et recapturée, on cherche d'abord à obtenir leurs versions résiduelles $R1$ et $R2$, chaque version étant respectivement la différence entre l'image originale et celle filtrée par un filtre passe-bas simple. Pour un pixel X_j de l'image originale, le pixel correspondant dans $R1$ (respectivement $R2$) représente la différence de valeurs de niveaux de gris entre X_j et la valeur moyenne de ses deux pixels voisins horizontaux (respectivement verticaux). Les deux images ainsi obtenues décrivent les bords et le bruit de l'image, mettant en avant les altérations de flou et anti-aliasing. Ces altérations n'ayant pas de liens avec la couleur des pixels, les images originales sont directement converties en niveaux de gris.

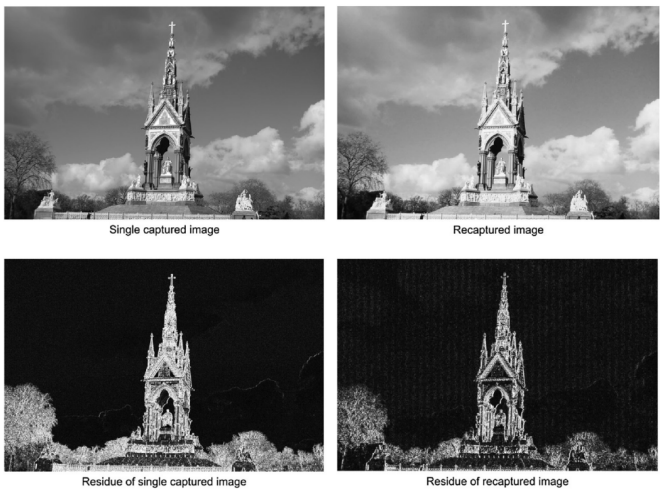


FIGURE 1 – Dans la rangée supérieure, une paire d'images capturées et recapturées en niveaux de gris. Dans la rangée du bas, leur version résiduelle.

Chaque image résiduelle est ensuite découpée en un chevauchement de petites régions, ou patchs, de 5x5 pixels. Les éléments de de chaque patch $P^{(k)}$ sont notés $p_{i;j}^{(k)}$ avec $i, j \in \{1, 2, 3, 4, 5\}$ et $k \in \{1, 2, \ldots, k\}$. On rassemble chaque pixel de chaque patch de même coordonnées dans un vecteur $V_{i,j}$, avec i et j coordonnées du patch. On calcule ensuite le coefficient de corrélation $c_{i,j}$ (horizontal pour $R1$ et vertical pour $R2$) entre le vecteur correspondant au pixel central de chaque patch $V_{3,3}$ et les 25 autres vecteurs :

$$c_{i,j} = \rho_{V_{3,3},V_{i,j}} = \frac{\sum_{k=1}^{K}\left(p_{3;3}^{(k)} - \overline{p(3,3)}\right)\left(p_{i;j}^{(k)} - \overline{p(i,j)}\right)}{\sqrt{\sum_{k=1}^{K}\left(p_{3;3}^{(k)} - \overline{p(3,3)}\right)^2}\sqrt{\sum_{k=1}^{K}\left(p_{i;j}^{(k)} - \overline{p(i,j)}\right)^2}} \tag{1}$$

Où $p_{3;3}$ et $p_{i;j}$ sont les moyennes des éléments dans $V_{3,3}$ et $V_{i,j}$, et où $i, j \in \{1, 2, 3, 4, 5\}$. On obtient deux matrice de coefficients de corrélation horizontaux et verticaux de taille 5x5. Il existe une forte symétrie entre les deux parties séparées par la diagonale majeure des matrices, on choisit donc de ne garder que le triangle supérieur pour éviter la redondance, et on enlève le coefficient central, toujours égal à 1. Les valeurs des coefficients sont nettement plus élevées dans la matrice de l'image originale que dans la matrice de l'image recapturée : cette différence implique une forte capacité de discrimination.

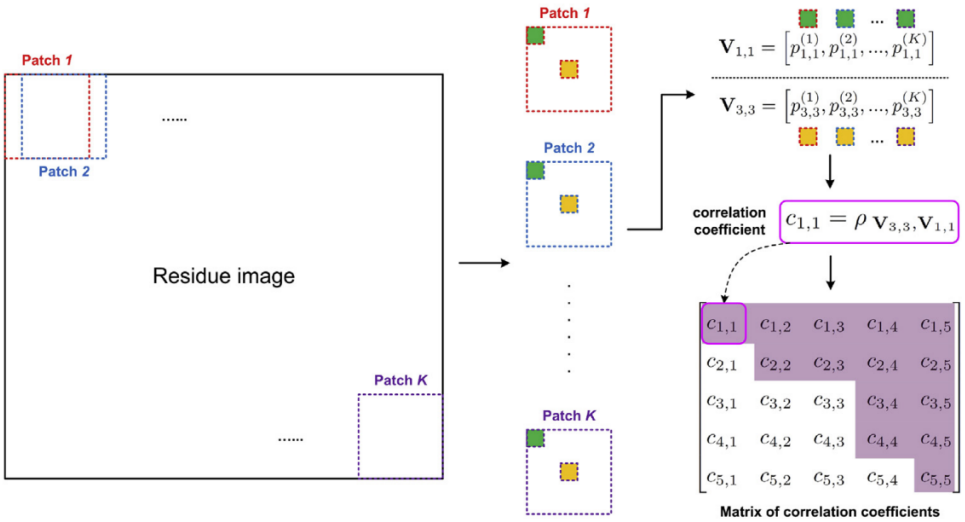


FIGURE 2 – Extraction des patchs et calcul des coefficients de corrélation par pixel, en prenant $c_{1,1}$ comme exemple. On conserve le triangle supérieur de la matrice de coefficients.

Finalement, chaque matrice (Deux pour chaque image résiduelle) est utilisée pour entraîner un classificateur à base de machines de vecteurs à support (SVM), qui servira d'outil de prédiction pour les futures images à comparer. Le classificateur SVM utilisé est un réseau neuronal prenant en entrée une matrice de coefficients de corrélation et renvoie 0 s'il considère l'image comme étant originale, et 1 sinon. L'entraînement consiste à labelliser les matrices d'images originales et recapturées et de les fournir au classificateur.

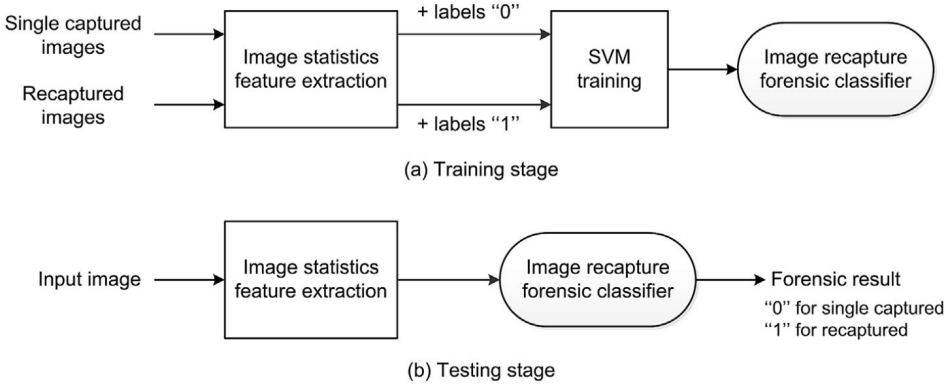


FIGURE 3 – Schéma fonctionnel (a) de la phase d'entraînement et (b) de la phase d'essai.

3 Détection par analyse de descripteurs LTC

La deuxième méthode [2] se concentre sur les altérations de couleur et de luminosité qui se produisent lors de la recapture. Les caméras grand public utilisent un réseau de filtres colorés (CFA) pour capturer différentes composantes de couleur, ou chaque pixel du filtre capture la couleur qui lui est attribuée (rouge, vert ou bleu). Des algorithmes d'interpolation permettent ensuite d'estimer les couleurs manquantes et d'obtenir les trois canaux de couleur complets. Cela introduit des corrélations entre ces canaux, qui peuvent changer lors de la recapture de l'image.

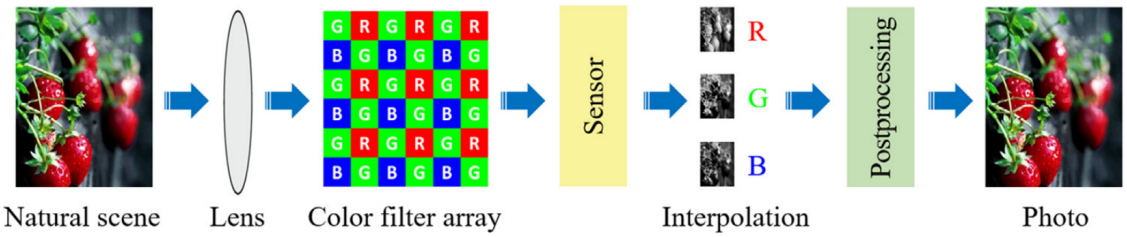


FIGURE 4 – Procédé d'imagerie d'un appareil photo grand public

Pour mieux capturer ces différences, l'image traitée est convertie de l'espace couleur RVB à l'espace couleur HSV (Teinte (H), Saturation et Valeur), l'espace HSV étant plus adapté pour représenter les variations de luminosité et de couleur. L'image ainsi définie permettra une capture des corrélations entre pixels à petite échelle. Afin de capturer les corrélations de plus grande échelle, une image moyenne groupée I^* est obtenue en prenant la somme des valeurs de pixels de l'image d'origine I sur des régions de taille $2 * 2$:

$$I^*(x, y, z) = \sum_{u=0}^{1} \sum_{v=0}^{1} \frac{I(2x - u, 2y - v, z)}{4} \tag{2}$$

Où $x \in \{1, 2, \ldots, \lfloor \frac{M}{2} \rfloor\}$, $y \in \{1, 2, \ldots, \lfloor \frac{N}{2} \rfloor\}$, $z \in \{1, 2, 3\}$, et $\lfloor \cdot \rfloor$ représente la partie entière.

Sont ensuite obtenues des cartes de différences du second ordre, représentant la valeur de différence entre un pixel et ses voisins pour une direction (horizontale, verticale, diagonale) et une caractéristique (H, S, V) donnés. En prenant pour exemple le canal de teinte de I noté I_H et $I_H(i, j)$ la valeur d'un pixel à la position (i, j), la carte différencielle du second ordre dans la direction horizontale est définie comme suit :

$$D^{(h)}_{I_H} = 2I_H(i, j) - I_H(i, j - 1) - I_H(i, j + 1) \tag{3}$$

De la même manière que pour l'image originale, on obtient les cartes de différence du second ordre de l'image moyenne groupée.

Ces cartes de différences peuvent refléter les corrélations entre pixels d'un même direction, mais négligent les corrélations entre des directions différentes. Pour ajouter une dimension supplémentaire, on utilise des cartes d'erreur de prédiction : des prédicteurs linéaires tentent de prédire la valeur d'un pixel en fonction de ses voisins dans différentes directions. En utilisant la carte de différence I_H comme exemple, le prédicteur linéaire pour la magnitude des cartes de second ordre est donné par :

$$|D^{(h)}_{I_H}| = w_1|D^{(v)}_{I_H}| + w_2|D^{(d)}_{I_H}| + w_3|D^{(c)}_{I_H}| \tag{4}$$

Où w_k sont les poids et $|\cdot|$ représente la valeur absolue. On obtient la carte d'erreur de prédiction $P^{(h)}_{I_H}$ de la manière suivante :

$$P^{(h)}_{I_H} = \log_2(V_h) - \log_2(|Q_h \vec{w}|) \tag{5}$$

Où V_h est la matrice colonne contenant les valeurs de $D^{(h)}_{I_H}$, Q_h une matrice de 3 colonnes contenant $D^{(v)}_{I_H}$, $D^{(d)}_{I_H}$ et $D^{(c)}_{I_H}$ avec v, d et c représentant les 3 autres directions (verticale, diagonale et contre-diagonale), et $\vec{w} = (w_1, w_2, w_3)^T$. On effectue le même calcul pour obtenir les cartes d'erreur de prédiction de l'image moyenne groupée.

Finalement, un histogramme LTC normalisé est calculé à partir des cartes d'erreur de prédiction. Pour l'obtenir, on utilise un modèle ternaire local (LTP). On divise la carte d'erreur de prédiction en régions de taille $3 * 3$, puis on applique la fonction $f(E_i, E_c, t)$ à 3 paramètres :

$$f(E_i, E_c, t) = \begin{cases} +1, & E_i > E_c + t \\ 0, & |E_i - E_c| \leq t \\ -1, & E_i < E_c - t \end{cases} \tag{6}$$

Où E_c est le pixel central du patch et E_i ses pixels voisins. t est un seuil spécifié par l'utilisateur, fixé à 2 dans cet exemple. On obtient une matrice, ou motif ternaire, ensuite divisée en 2 matrices ou motifs inférieurs et supérieurs. les codes binaires des motifs supérieur et inférieur sont cumulés pour obtenir les codes LTC supérieur et inférieur, respectivement.

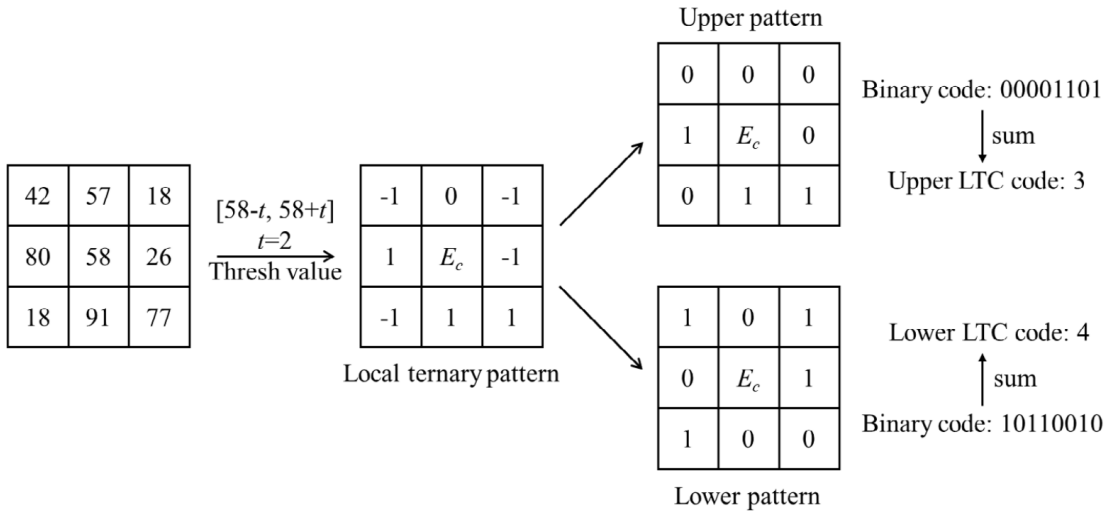


FIGURE 5 – Calcul du code LTC

L'histogramme LTC normalisé $H(k)$ pour l'ensemble des motifs inférieurs F_l et supérieurs F_u d'une carte d'erreur de prédiction $P^{(*)}$ de taille $U * V$ est donné par :

$$H(k) = \frac{1}{U * V} \sum_{p=1}^{U} \sum_{q=1}^{V} \ell(F_*(p, q), k) \tag{7}$$

Où $k \in \{0, 1, \ldots, 8\}$ et $* \in \{u, l\}$. La fonction $l()$ produit 1 si ses deux paramètres sont égaux, sinon elle produit 0. Enfin, la caractéristique LTC est obtenue à partir des deux histogrammes LTC de l'image originale et moyenne groupée.

De la même manière que dans la méthode précédente, on entraîne un réseau neuronal avec en entrée les caractéristiques LTC labellisées et en sortie une réponse binaire, 0 pour une image originale et 1 pour une recapturée.

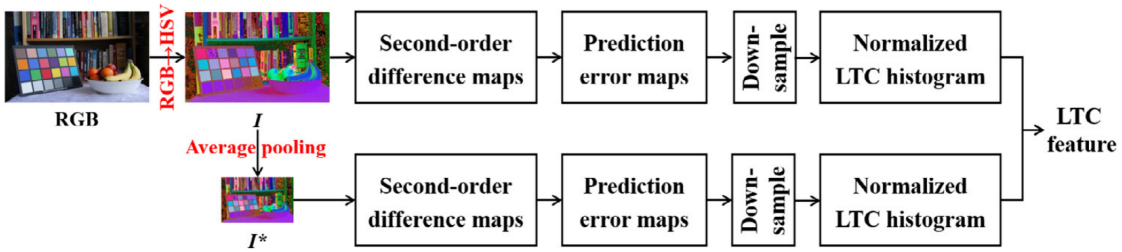


FIGURE 6 – Schéma du processus d'extraction des caractéristiques LTC

Références

[1] A simple and effective image-statistics-based approach to detecting recaptured images from LCD screens. *Digital Investigation*, 2017. https://doi.org/10.1016/j.diin.2017.10.001

[2] Recaptured image forensics based on local ternary count of high order prediction error. *Image and Vision Computing*, 2022. https://doi.org/10.1016/j.image.2022.116662